

司文智

性别：男 | 年龄：24 岁 | 政治面貌：中共党员 | 英语（CET-4）
电话：17396325793 | 邮箱：siwenzhi@163.com
个人主页：<https://siwenzhi.github.io>
个人博客：https://blog.csdn.net/weixin_52341477 （所发技术文章阅读量 66 万+）



教育背景

2024. 09 – 2027. 06	郑州轻工业大学	软件工程 硕士
研究方向：RAG、Agent、知识图谱、信息检索、自然语言处理		
荣誉奖项：研究生学业奖学金		
2020. 09 – 2024. 06	郑州升达经贸管理学院	软件工程 本科
荣誉奖项：河南省优秀学士学位论文、河南省大学生程序设计竞赛（ACM-ICPC）铜奖、蓝桥杯省赛二等奖、学业优秀奖学金		

专业技能

- 开发语言及软件 Python、Java、Linux、Docker、Redis、MySQL；
- 开发框架 LangChain、FastMCP、FastAPI、Elasticsearch、Spring AI、Spring Boot、Vue；
- 熟悉 PyTorch、LLaMA-Factory、vLLM，具备大模型构建、训练微调、部署及 RAG 检索优化、Agent 开发经验；

科研论文

S²P-RAG: Structural Specificity and Pair-Aware Path Prioritization for Graph-Based Retrieval-Augmented Generation （AAAI-2027 在审）
Automatic Construction of Multi-Layer Knowledge Graphs with Large Language Models
ChineseCSCW-2025, EI 会议

科研经历

2024.10 – 至今	多源异质多模态数据的知识图谱构建及检索技术研发
项目简述：	依托导师国家青年科学基金项目，面向多源异构数据开展知识组织、融合与检索研究，构建知识图谱平台，实现异构数据采集、图谱构建、融合推理、语义分析与关联检索等功能。成果获河南省科学技术进步二等奖。
个人职责：	负责平台设计与核心功能实现，完成多源数据采集、单源知识图谱构建、多源图谱融合与扩充、图谱节点检索及可视化等模块开发；
个人成果：	1 篇论文在审（AAAI2027），1 篇 EI 论文已发表；

学生工作

2025. 09 – 2026. 09	软件学院研究生党支部 组织委员
负责党建学习组织、支部会议筹备及日常党务工作。	
2021. 10 – 2022. 10	校算法协会（ACM）会长
负责协会运营，组织策划算法竞赛及公开课、成员培训与日常管理，有百人活动组织经验。	

个人概述

- 具备较强的代码开发能力和丰富的项目实践经验，能够独立完成项目的设计、开发与落地；
- 具备丰富的活动组织、沟通协调及文字写作经验，具有良好的抗压、学习和适应能力，能够快速融入新环境并胜任新的工作任务；

后附个人详细项目经历，请翻页。

基于 Agent 的律所智能案件研判与知识检索平台 2025.07 – 2026.05 项目负责人

- 项目类型：企业项目
- 项目背景：面向律所案件研判与知识协同场景，融合 LLM、RAG、知识图谱与 Multi-Agent 技术，构建覆盖材料解析、法律检索、历史案件检索、关系分析、人际关系挖掘与综合报告生成的智能案件分析平台。
- 技术栈：LangChain、Elasticsearch、FastMCP、LoRA、BM25、RRF、MinerU 等
- 项目实现：
 - 离线索引构建：**基于 MinerU 解析 PDF、扫描件等非结构化案件材料，结合 LLM 与向量模型完成关键信息抽取、结构化整理及向量化存储，为后续检索与案件研判提供统一数据基础；
 - 法律条文与案件检索：**基于 Elasticsearch 构建法律知识库与历史案件检索库，实现 BM25 与向量检索混合召回，结合领域意图路由、RRF、Reranker 与 LLM Judge 完成多阶段检索、结果融合及高价值知识筛选；
 - 多 Agent 协同：**基于 LangChain 构建法律研究、历史案件研究、关系研判和报告生成 Agent，融合 Tool Calling、MCP 调用，实现多源证据生成结构化案件研判报告；
 - LoRA 微调：**基于律所案件报告与标准化文书进行 LoRA 微调，统一模型在不同案件中的专业措辞、报告结构与分析风格；
 - 工程化集成：**采用 Spring Boot 3、Vue3 构建业务端、FastAPI 承载 AI 服务，结合 LangSmith 进行链路追踪，使用 Docker 进行容器化部署；

学者信息异构数据融合与知识图谱检索平台 2024.11 – 2025.03 项目负责人

- 项目类型：科研项目、获河南省科学技术进步二等奖
- 项目背景：面向多源异构知识的融合与检索需求，以百度百科、快懂百科及高校官网等多源数据为基础，经数据采集、知识抽取与图谱构建，实现异构知识的语义对齐、冲突判断与融合补全，并提供知识检索与图谱可视化功能。
- 技术栈：Spring Boot、Vue3、Selenium、MySQL、Redis、LLM、知识图谱、NER
- 实现方法：
 - 多源异构数据采集：**基于 Selenium 构建自动化数据采集模块，对同一实体的多源描述进行抓取、清洗与本地化存储，为后续知识抽取与图谱构建提供数据基础；
 - 知识图谱构建：**对各数据源独立进行实体、属性及关系抽取，完成结构化知识表示，并分别构建知识图谱，保留知识来源信息，避免不同来源数据在融合前发生信息污染；
 - 多源异构知识融合：**基于多源异构数据融合机制，结合 LLM 对实体、属性及取值进行语义判断与冲突识别，协同完成实体对齐、属性合并与缺失知识补全，实现多源知识图谱的融合、推理与补充；
 - 语义分析与知识检索：**对用户查询进行语义分析与关键词提取，将查询关键词映射至知识图谱节点，结合节点及关联关系完成模糊检索和关联知识查询，实现从自然语言查询到图谱知识检索的完整流程；
 - 工程化与可视化：**使用 Spring Boot + Vue3 搭建前后端分离系统，MySQL 存储实体、关系及数据来源等结构化信息，Redis 缓存高频查询与中间结果；Vue3 实现单源图谱、融合图谱、节点关联图谱及全局知识图谱的交互式可视化展示；

项目类型：企业项目

项目背景：整合《中国居民膳食指南》、食品营养成分表等相关资料，结合 LLM 与 RAG 技术，开发面向日常饮食场景的食品营养智能问答系统，为用户提供食品营养查询、营养成分分析、饮食搭配及健康饮食知识问答服务。

技术栈：Vllm、PaddleOCR、LangChain、Vue3、Redis、Elasticsearch、BM25、RRF、Qwen3-Embedding-8B、BGE-Reranker 等

实现方法：

1. 知识库构建：使用 PaddleOCR 对膳食指南、营养科普等文档进行文本识别与解析，完成文本数据清洗、语义分块与元数据标注；基于 vLLM 本地部署 Qwen3-Embedding-8B 完成文本向量化，结合 Elasticsearch 构建食品营养领域知识库，实现文本与向量统一索引；

2. 查询优化：针对食品别名、口语化描述及复杂饮食问题，结合历史对话进行用户意图提取及 Query Rewrite，将自然语言查询转换为结构化检索条件；Redis 保存多轮会话上下文，增强连续问答的语义理解能力；

3. 检索与精排优化：基于 Elasticsearch 实现 BM25 与向量检索双路召回，通过 RRF 融合多路检索结果；使用 Reranker 对候选知识片段进行相关性重排序，结合元数据过滤、文档去重与 Top-K 截断优化最终上下文，兼顾精确匹配与语义召回，提升食品营养知识检索的准确性；

4. 生成与回答优化：基于 Spring AI 编排完整 RAG 问答链路，通过 Few-shot + CoT 引导模型结合检索证据完成食品营养分析与饮食建议，并在回答中返回对应知识来源，提高回答的专业性、可解释性与可追溯性；

5. 系统交互与性能优化：使用 Vue3 实现流式问答、历史会话及知识来源展示，使用 Redis 缓存高频问答结果，降低重复检索及模型调用开销；

项目类型：校级课题、此项目论文获河南省优秀学士学位论文

项目背景：面向高校学术论文管理与检索场景，针对传统关键词匹配存在语义区分度不足、检索结果相关性不高等问题，研究基于 TF-IDF 的文本特征表示与论文相关性计算方法，设计并实现面向论文题目、摘要及关键词等文本信息的学术论文检索系统。

技术栈：Spring Boot、Vue、MySQL、TF-IDF、BM25、中文分词、文本相似度计算

实现方法：

1. 论文文本预处理：对论文题目、摘要、关键词等文本进行中文分词、停用词过滤及文本规范化处理，构建论文语料库与词项索引，为后续特征计算与检索提供基础；

2. TF-IDF 特征建模：基于词频（TF）与逆文档频率（IDF）计算词项权重，将论文文本转换为高维特征向量，降低高频通用词对检索结果的影响，增强具有区分度关键词的权重；

3. 论文相关性检索：对用户查询进行同样的文本预处理与特征表示，通过向量相似度计算查询与候选论文之间的相关程度，并结合 BM25 等文本相关性指标进行排序，返回相关论文结果；

4. 检索系统实现：基于 Spring Boot+Vue 实现论文管理与检索功能开发，MySQL 存储论文元数据及相关信息，实现论文录入、条件查询、全文检索与相关度排序等功能。